项目速览：NE Seeking 中的欺骗——检测与恢复

一分钟回到项目的基础脉络

一句话总览： 一群摸黑爬山的 AI 靠“抖动+解调”自己走向 Nash 均衡； 坏 AI 偷用受害者的探测频率、注入假信号，把它骗到一个假均衡还让它无知无觉 （Poveda 组的攻击）；防御没人做——我做的是用第二个秘密频率“看穿”欺骗、 再换频率“挣脱”欺骗。

七层脉络（从最底层往上搭）

第1层：一群 AI 在博弈，目标是 Nash 均衡

好几个 agent 在同一环境里各追各的目标，但选择互相牵制：我的最优取决于你怎么动。 稳定点叫 **Nash 均衡**——到那儿，每个人单独改自己的动作都不会让自己更好，于是谁都不动。 整个研究就是围绕“agent 如何自己走到这个均衡”。

第2层：它们看不见地图，只能“摸”

关键难点：agent 不知道自己的收益函数长什么样（没公式、没地图）， 只能“做个动作、测一下收益”。像站在浓雾里的山上，只感觉得到当前海拔，想爬到山顶。 这叫 **model-free（无模型）** 设定。

第3层：最基础的招——抖一抖，看反应（Extremum Seeking）

往左右各挪一小步试探：哪边海拔升高就往哪走。把“抖动”做成一个小正弦摆动 $\sin(\omega t)$（ω = 你的“音调/频率”），再看收益怎么跟着摆。 把收益乘上自己的摆动信号再取平均，得到的数就是上坡方向和陡度 ——数学上叫**梯度**，这步操作叫**解调（demodulation）**。 朝这个方向挪、再抖、再解调，最后停在“再抖也不变好”的点 = 最优点 / Nash 均衡。 这套方法叫 **Extremum Seeking**，是控制论几十年的成熟工具，是整个研究的底座。

第4层：多人怎么不打架——各哼各的音调（正交性）

山上不止一个 agent，怎么不把别人的抖动误当自己的? **每个人用一个只属于自己的频率**。数学事实：两个不同频率的正弦相乘再平均正好抵消为零， 只有同频率相乘平均才留下东西。所以每个人解调时只挑得出自己音调的信息，别人的自动被滤掉。 这个“异频相消、同频保留”的**正交性**，是后面一切的关键机关。 到此为止全是干净的老理论，问题还没出现。

第5层：问题从哪来——有人学坏了（攻击）

出处是 Poveda 组 2024 年的论文（arXiv:2407.05168，即项目里那篇）。 他们问：若混进一个有隐藏目标、又懂这套机制的**坏人**会怎样? 坏人**偷用受害者的音调** ω_v，把它混进自己的动作里摆动。 由第 4 层那条规则，同频不会被滤掉，于是受害者把坏人塞进来的假信号也当成自己的上坡方向， 被牵到坏人挑好的位置停下。最阴险的是：受害者停下时“感觉一切正常” （抖一抖收益不再变好），却站在半山腰的次优点——**被骗了却毫不知情**。 这个假稳定点叫**欺骗性均衡（DNE）**，论文证明坏人能稳稳把受害者钉在那里。

第6层：空白在哪——防御没人做

Poveda 组这几篇（2024/2025/2026）全在讲坏人怎么攻击、多有效。 但**受害者能否察觉被骗、察觉后能否挣脱**——即**防御侧（检测 + 恢复）**， 目前没有任何已发表工作。这就是本项目的落点：不是补小缝，是真实空白。

第7层：解决办法——两个思路，一个原语

核心洞察一句话：**坏人的全部筹码，是那个被偷走的共享音调** ω_v。

- **怎么察觉（检测）：** 让受害者再用一个坏人不知道的秘密音调 ω_v' 探一次。 坏人没在上面做手脚，这次探到的是未被污染的真实坡度。两个读数一对比—— 被污染的音调说“平了”、秘密音调说“其实还斜着”——**差距不为零 = 被骗**。 差距大小正好是坏人注入的强度：诚实为零（不误报）、被骗明显大于零（不漏报）， 设个门槛就能可靠报警。
- **怎么挣脱（恢复）：** 报警后受害者把音调换成新的秘密值。 坏人还在对旧音调塞假信号，但由正交性，旧音调的干扰对新音调自动全抵消。 操纵通道当场切断，受害者顺真实坡度滑回真正的山顶。筹码没了。

检测与挣脱是同一个原语——“换一个对手不知道的频率”：一个用来看见欺骗，一个用来摆脱欺骗。

出处与作者（写 related work 时用）

分清三层，别混：

- **底座（老）：** “探测+解调、各用独有频率”的 NE seeking 框架来自 Frihauf–Krstic´–Ba⌧ar 2012（论文引用 [11]）， Krstic´是 Extremum Seeking 奠基人之一。
- **攻击（新，本领域首创）：** 在诚实框架上加坏人、偷频率注入造 DNE， 出自 Tang, Javed, Chen, Krstic´, Poveda，“Deception in Nash Equilibrium Seeking”, arXiv:2407.05168。第一作者 Michael Tang 是 Poveda 在 UCSD 的学生； 论文自述是“首个研究 model-free NE seeking 稳定欺骗机制”的工作。
- **防御（空白）：** 检测 + 恢复，无已发表工作 = 本项目贡献。

措辞提醒： 论文的准确说法是坏人拥有受害者探测信号的**“特权/私有信息”**（privileged information），不是每次去“偷”；危险性来自信息不对称。 论文一般形式还允许坏人同时用多个受害者的频率、注入幅度由动态反馈调—— 我们讲的“单受害者、单频率”是其最简版本。

术语对照（比喻 ↔ 真实）

比喻	真实术语
摸黑爬山	model-free 优化 / NE seeking
海拔	收益 / 代价 J_i
抖一抖看反应	加正弦探测 $a\sin(\omega t)$ + 解调
音调 / 频率	探测频率 ω_i
收益乘摆动再平均	解调，$\approx$ 梯度
异频相消、同频保留	正交性（extremum seeking 能工作的关键）
山顶 / 谁都不想动	Nash 均衡
被骗到的半山腰	欺骗性均衡（DNE）
第二个秘密音调	秘密探测频率 ω_v'，得干净真梯度 C_v'
两个读数的差距	检测量 $D_v = \lvert C_v' - C_v\rvert = \lvert\delta_d\rvert\,\lvert\partial_d J_v\rvert$
换音调切断通道	重新随机化探测频率（恢复）

项目现状与下一步

- **已完成：** 教授要求的“数学上证明方法可行”已交付—— 完整证明文件（检测量 D_v 的 soundness / completeness / separation 三条 + 换频率恢复的稳定性）。
- **关键理论点：** 单频 C_v 在 DNE 处会归零、看不见欺骗（盲性）； 必须用第二个秘密频率作差，真梯度抵消、只剩注入项，才可检测。
- **下一步：** 二次型博弈的**仿真验证**（诚实 / 被欺骗 / 带检测三条轨迹，画出 D_v）； 多 agent 下定位欺骗者仍是开放问题；远期向 LLM-agent 场景延伸。