模型无关 Nash 均衡搜索中的欺骗检测与恢复

双解调分析 —— 项目笔记

何静宜　UC San Diego, ECE

2026 年 8 月

一句话概括。 三条结果共用同一个原语：**换一个欺骗者没有注入的频率去解调**。用它比较，得到检测；用它更新，得到恢复。三条结果各自的边界也都定位清楚了：检测的边界是探针保密而非信息论不可能性；恢复的边界是欺骗者自己的积分状态发散；而残差的边界告诉我们真正的设计变量是 k/ω，不是 a。

目录

1 速览：整条逻辑链 **2**

2 设定 **2**

2.1 Washout 为什么不是可选的 3

2.2 定义与假设 4

3 引理 1：全部东西的基础 **4**

4 主结果一：盲性 **5**

5 主结果二：检测 **5**

6 检测器的攻击面 **6**

6.1 遵守保密者：贪心是吵的 6

6.2 违反保密者：精确规避 6

7 保密是时序条件，不是静态条件 **7**

8 主结果三：恢复 **8**

8.1 恢复之后：积分饱和与三个出口 9

9 设计变量是 k/ω，不是 a **9**

10 数值验证 **10**

10.1 解析基准（先解，不拟合） 11

10.2 汇总表 11

10.3 值得单独说明的几项 11

11 开放问题与下一步 **12**

A 附录：汇报要点 **12**

1 速览：整条逻辑链

1. **欺骗**：欺骗者在受害者自己的探测频率 ω_v 上注入，把系统从真 Nash 均衡 $u^\star$ 推到欺骗均衡（DNE）u^*。
2. **盲性**（引理 2）：在 DNE 处，受害者的解调信号 C_v 归零，和在诚实 NE 处一模一样。所以 C_v 无法自证诚实。
3. **检测**（定理 1）：在欺骗者没有注入的探针 ω_v' 上再做一次解调。真梯度出现在两个通道里、相减时抵消，剩下的恰好是注入项：$D_v = |\delta_d|\,|\partial_d J_v| + O(a^2)$，在每个 t 都成立。
4. **定价**（命题 1）：对遵守保密的欺骗者，收益与可检测性单调锁死。压低到阈值以下，收益也被压到接近零。
5. **规避**（命题 2）：若欺骗者在两个探针上同时注入相同幅度，检测器精确失效，且这个规避对攻击者第一阶不花钱。所以整个保证是探针保密，不是无条件可靠性。
6. **保密是时序条件**（注 5–6）：欺骗者原则上能从自己的收益频谱里估出 ω_v'，于是安全性变成一场赛跑 $T_{\text{hop}} < T_{\text{acq}}$。跳频在稳定性上是免费的。
7. **恢复**（定理 2）：把驱动更新的频率重抽到 ω_v''，交叉项平均为零，注入从受害者动态中消失，指数收敛回 $u^\star$。
8. **终结**（推论 2）：切频后欺骗者的积分状态线性发散。三个出口——饱和、发散、放弃——都终结欺骗。
9. **设计**（注 10–11）：残差在 a 上非单调。真正的设计变量是 k/ω，最优幅值 $a^\star \propto \sqrt{k/\omega}$。

编号对照。 本笔记独立编号，与英文稿的对应关系如下（左：本笔记，右：英文稿）：引理 1 = Lemma 1；引理 2 = Lemma 2；定理 1 = Theorem 3；推论 1 = Corollary 4；命题 1 = Proposition 5；命题 2 = Proposition 6；定理 2 = Theorem 7；推论 2 = Corollary 8。

2 设定

两个玩家：受害者 v、欺骗者 d，标量动作 $x_v, x_d \in \mathbb{R}$，代价 $J_v(x_v, x_d)$、$J_d(x_v, x_d)$。动作携带正弦探测：

$$x_v = u_v + a\sin(\omega_v t)\,\big[+\ a\sin(\omega_v' t)\big], \tag{1}$$

$$x_d = u_d + a\sin(\omega_d t) + a\,\delta_d(t)\sin(\omega_v t), \tag{2}$$

探测幅值 $a > 0$。**攻击的全部内容就在 (2) 的最后一项**：欺骗者在受害者自己的探测频率上注入。方括号里的第二探针只进入动作、不驱动更新，只有第 5 节的检测器使用它。

每个玩家先把测得的收益过一个转折频率为 $\omega_h > 0$ 的 washout（高通）滤波，再解调：

$$\dot{z}_i = -\omega_h\big(z_i - J_i(x)\big), \qquad h_i := J_i(x) - z_i, \qquad i \in \{v, d\}, \tag{3}$$

$$\dot{u}_v = -\frac{2k}{a}\,\overline{h_v \sin(\omega_v t)}, \qquad \dot{u}_d = -\frac{2k}{a}\,\overline{h_d \sin(\omega_d t)}, \qquad k > 0. \tag{4}$$

注意受害者的更新只用 ω_v；第二探针进入动作但不驱动更新，这一点在第 6 节很关键。欺骗者用积分反馈把注入幅度推向自己的目标收益：

$$\dot{\delta}_d = \varepsilon\big(J_d(x) - J_d^{\mathrm{ref}}\big), \qquad \varepsilon > 0. \tag{5}$$

令 $\delta_d \equiv 0$ 就退化成诚实的 NE 搜索。偏导 $\partial_v J_v := \partial J_v/\partial x_v$ 等均在慢状态 $u = (u_v, u_d)$ 处求值，$\overline{f} := \lim_{T\to\infty} \frac{1}{T}\int_0^T f\,dt$ 在 u, δ_d 冻结下取。

2.1 Washout 为什么不是可选的

注 1 (Washout 的必要性). 没有 (3)，更新 (4) 被 J_v 本身驱动。把 $J_v(x)$ 在 u 处展开：

$$J_v(x) = \underbrace{J_v(u)}_{O(1),\ \text{直流}} + \underbrace{a\sin(\omega_v t)\,\partial_v J_v}_{O(a),\ \text{你要的}} + \underbrace{a\sin(\omega_d t)\,\partial_d J_v}_{\text{别人的探针}} + O(a^2).$$

乘上 $-\frac{2k}{a}\sin(\omega_v t)$ 后出现**致命的不对称**：信号项自带一个 a，与前面的 $1/a$ 对消，得到干净的 $O(k)$；直流项不带，$1/a$ 就赤裸裸留着，得到 $O(k/a)$。

为什么“平均为零”救不了

$\overline{\sin(\omega_v t)} = 0$ 说的是长期平均为零。但真实的 $u_v(t)$ 要把这一项积分出来，而正弦的积分是余弦：

$$\int^t -\frac{2k}{a} J_v(u)\sin(\omega_v \tau)\,d\tau = \frac{2kJ_v(u)}{a\omega_v}\cos(\omega_v t).$$

零均值，但不是零——它是一个幅度 $2k|J_v|/(a\omega_v)$ 的**纹波**，骑在 u_v 上面。
判据不是纹波大不大，而是纹波和探针比谁大：

$$\frac{2k|J_v|}{a\omega_v} < a \iff \omega_v > \frac{2k|J_v|}{a^2}.$$

代入本文参数（$k = 0.3$, $a = 0.05$, $J_v \approx 0.59$, $\omega_v = 2\pi \cdot 5$）：纹波 $= 0.225$，而探针只有 $a = 0.05$——**纹波是探针的 4.5 倍**，回路失稳。要满足条件需 $\omega_v \gg 142$ rad/s，即约 225 Hz 而非 5 Hz。更糟的是这个要求含 a^{-2}：a 减半，频率要求涨 4 倍。两个目标二次地互斥。

加上 washout 后，滤波器把慢变的 $J_v(u)$ 当直流跟踪并减掉（只要 $\omega_h \gg k$），留下的交流部分是 $O(a)$。于是：

	无 washout	有 washout
进解调的信号	$O(1)$	$O(a)$
乘 $2k/a$ 之后	$O(k/a)$	$O(k)$
造成的纹波	$k/(a\omega)$	k/ω
频率要求	$\omega \gg k/a^2$	$\omega \gg k/a$
本文参数下纹波/a	4.5	**0.19**

Washout 没有消灭纹波，只是降了一阶。剩下的**相对纹波**

$$\nu := \frac{\text{纹波}}{a} = \frac{k}{a\,\omega_{\min}} = \frac{0.3}{0.05 \times 31.4} = 0.191$$

正是第 9 节的主角。它以 $O(\nu^2)$ 进入检测器残差： $0.19 \times 0.191^2 = 0.0068$——**这就是数值中的诚实噪底** 0.00683。 没有 washout，噪底会大 $1/a^2 = 400$ 倍量级，任何阈值都无从谈起。

2.2 定义与假设

定义 1 (欺骗 Nash 均衡 DNE)**.** (u^*, δ^*) 满足

$$\underbrace{\partial_v J_v(u^*) + \delta^*\,\partial_d J_v(u^*) = 0}_{\text{受害者以为自己最优}}, \qquad \underbrace{\partial_d J_d(u^*) = 0}_{\text{欺骗者真的最优}}, \qquad \underbrace{J_d(u^*) = J_d^{\text{ref}}}_{\text{积分器静止}}. \tag{6}$$

假设 1 (正则性)**.** $J_v, J_d \in C^3$ 于开操作集 $U \subset \mathbb{R}^2$ 上。

假设 2 (探针与滤波器选择)**.** $\omega_v, \omega_v', \omega_d > 0$ 互异且非共振： $m_1\omega_v + m_2\omega_v' + m_3\omega_d \neq 0$ 对一切 $0 < |m_1| + |m_2| + |m_3| \le 3$ 的整数成立。 Washout 转折频率卡在慢快两个时间尺度之间： $k \ll \omega_h \ll \omega_{\min} := \min\{\omega_v, \omega_v', \omega_d\}$。

这条假设给出标准的正交关系：

$$\overline{\sin(\omega_i t)\sin(\omega_j t)} = \tfrac{1}{2}\mathbb{1}[\omega_i = \omega_j], \qquad \overline{\sin(\omega_i t)\sin(\omega_j t)\sin(\omega_\ell t)} = 0. \tag{7}$$

界 $|m| \le 3$ 恰好是主阶论证所需；三阶 Taylor 余项会产生 $|m| = 4$ 的组合 （例如由 $\sin^3 \omega_v t$ 产生的 $3\omega_v$），但那只进入 $O(a^2)$ 偏差、不进入恒等式本身。

假设 3 (探针保密)**.** 欺骗者知道 ω_v 且只在该频率注入。它既不知道、也不注入受害者使用的任何其他频率—— 特别是第 5 节的监测探针 ω_v'，以及第 8 节的切换后频率 ω_v''。

假设 4 (有界注入)**.** 存在 $\bar\delta < \infty$ 使 $|\delta_d(t)| \le \bar\delta$ 对一切 t，且相应轨迹留在 U 内。 等价地，(5) 带有一个饱和或抗积分饱和环节。

假设 4 的地位很微妙：**欺骗成功期间它是空的**——在 DNE 处积分器静止， δ_d 自动有界；**恰恰在恢复之后它才不空**。这正是推论 2 的内容。

假设 5 (有效欺骗)**.** 存在 $c_0 > 0$ 使 $|\partial_d J_v(u)| \ge c_0$ 对一切 $u \in U$。 称 t 时刻欺骗活跃，若 $|\delta_d(t)| \ge \delta_{\min}$。

假设 6 (稳定的真 NE)**.** 诚实伪梯度流 $\dot u = -kG_{\text{hon}}(u)$ 有平衡点 $u^\star$，且 $-k\,DG_{\text{hon}}(u^\star)$ 是 Hurwitz 的 （例如强单调博弈）。

3 引理 1：全部东西的基础

引理 1 (两个通道的差别)**.** 在假设 2 下，沿平均动态，

$$\text{(a)}\quad C_v = \partial_v J_v + \delta_d\,\partial_d J_v + O(a^2), \qquad \text{(b)}\quad C_v' = \partial_v J_v + O(a^2). \tag{8}$$

机制。 在 ω_v 解调时，欺骗者的注入项 $a\delta_d \sin(\omega_v t)$ 与解调信号同频， $\overline{\sin^2(\omega_v t)} = \frac{1}{2}$ 使它存活下来；在 ω_v' 解调时， $\overline{\sin(\omega_v t)\sin(\omega_v' t)} = 0$，注入项消失。

> **两个通道的唯一差别就是注入项在不在。** 后面的一切都是这句话的推论。

4 主结果一：盲性

引理 2 (盲性)**.** 在 DNE 处，$C_v = O(a^2)$。

Proof. 把定义 1 的第一条代入引理 1(a)——括号里的东西按定义就是零。 □

于是：受害者盯着自己的更新信号，**永远看不出诚实与欺骗的区别**。 它的真梯度 $\partial_v J_v(u^*) = -0.2045$ 明明不为零，但它感知到的梯度是零。 动作残差也一样瞎：诚实 1.6×10^{-2} 对欺骗 1.5×10^{-2}。

注 2 (盲性不只是渐近的——但也不要误读数值). 数值上 $|C_v|$ 诚实为 1.5×10^{-13}，欺骗为 6.1×10^{-5}，看起来差了八个数量级， 像是可以利用。**不能**。两者都远在它们只被保证遵守的 $O(a^2) = 2.5\times10^{-3}$ 之下， 这个比值是无噪积分的假象。加上 $\sigma = 10^{-4}$ 的测量噪声， 两个值变成 4.4×10^{-5} 和 6.2×10^{-5}，比值 1.4—— 而同一时刻 D_v 依然是 0.0068 对 0.2057，分离 30 倍。

5 主结果二：检测

取 (4) 在监测频率 ω_v' 上的第二份拷贝，定义

$$D_v := \left| C_v' - C_v \right|. \tag{9}$$

定理 1 (检测恒等式)**.** 在假设 2–4 下，

$$\boxed{D_v = |\delta_d| \left|\partial_d J_v(u)\right| + O(a^2) \quad \text{在每个时刻 } t} \tag{10}$$

Proof. 引理 1(b) 减 (a)：$C_v' - C_v = -\delta_d\, \partial_d J_v(u) + O(a^2)$。 **真梯度 $\partial_v J_v$ 出现在两个解调里并相消，留下的恰好是 C_v 无法隔离的注入项**。 取绝对值。 □

注 3 (为什么是差，而不是 C_v' 单独). 这是最容易被追问的一点。在 DNE 处 $C_v = O(a^2)$，所以 D_v 与 $|C_v'|$ 一致。 但在诚实的暂态中 $C_v' = C_v \neq 0$，于是 $D_v = O(a^2)$ 而 $|C_v'|$ 大得像诚实梯度。**单测 $|C_v'|$ 会对每一次尚未收敛的诚实运行报警**；相减买到的是 “在每个 t 都有效”而不是“收敛后才有效”， 这正是 (10) 中那句话的内容。

共模抵消还使检测器比任一单独通道更锐利：数值中 C_v、C_v' 各自带约 0.010 的偏差， 而它们的差的噪底只有 0.0068，因为两个偏差在很大程度上是共模的。

推论 1 (可靠性、完备性、分离)**.** 设 $\eta(a,k,\omega) := \sup_t \left| D_v - |\delta_d|\,|\partial_d J_v(u)| \right|$ 为真实系统上的总残差。 若设计参数满足

$$\eta(a,k,\omega) \le \tfrac{1}{4}\,\delta_{\min} c_0, \tag{11}$$

并取 $\rho := \frac{1}{2}\delta_{\min} c_0$，则诚实时 $D_v \le \frac{1}{4}\delta_{\min} c_0 < \rho$， 欺骗活跃时 $D_v \ge \frac{3}{4}\delta_{\min} c_0 > \rho$。 故规则 “$D_v > \rho \Rightarrow$ 欺骗”对满足假设 3 的欺骗者 **既无误报也无漏报**。

注 4 (检测器是模型无关的). D_v 只用受害者自己的收益采样和自己的探针 ω_v, ω_v'—— 不需要 J_v 的模型，不需要知道欺骗者的身份、δ_d 或 J_d。 **它与 NE 搜索本身处在同一个模型无关的设定里。** 常数 c_0 只进入 ρ 的标定，而 ρ 也可以直接从一段已知诚实的区间里经验地定出来。

6 检测器的攻击面

以下两条必须成对呈现。它们回答两个不同的问题： 命题 1 问“不作弊的攻击者能不能靠攻得轻来躲过”， 命题 2 问“作弊的攻击者会怎样”。

6.1 遵守保密者：贪心是吵的

命题 1 (没有安静的利润). 设假设 2–6 成立，$\delta \mapsto u^*(\delta)$ 是 (6) 前两式 过 $u^*(0) = u^\star$ 的解分支（由隐函数定理，在 $\delta = 0$ 附近 C^1）。 记 $\pi := J_d(u^\star) - J_d(u^*)$ 为欺骗者相对诚实博弈的收益。则

(i) $D_v \geq c_0|\delta| + O(a^2)$;

(ii) $\pi(\delta)$ 连续且 $\pi(0) = 0$。

于是对任何阈值 $\rho > 0$，能被检测器读作诚实的欺骗者所能获得的收益上界满足

$$\bar{\pi}(\rho) := \sup\left\{|\pi(\delta)| : c_0|\delta| \leq \rho + O(a^2)\right\} \longrightarrow 0 \quad \text{当} \rho \to 0. \tag{12}$$

直觉

$D_v = |\delta_d|\,|\partial_d J_v|$——检测器读数正比于注入强度。 而攻击者的收益也来自注入：$\delta_d = 0$ 就是诚实、收益为零；δ_d 越大赚得越多。 **同一个量既决定你赚多少，也决定你有多显眼。**
所以阈值不只是在分类，它在定价：你把 ρ 调多严， 就把攻击者能偷偷拿走的收益压到多小。

数值：扫 J_d^{ref}（攻击者的贪心程度），收益与 D_v 单调，相关系数 $r = 0.9998$； 在 $\rho = 0.03$ 下能藏住的最贪攻击**只拿回诚实收益的** 4.5%。

6.2 违反保密者：精确规避

命题 2 (镜像欺骗者的精确规避). 设欺骗者在受害者的两个探测频率上都注入（违反假设 3）：

$$x_d = u_d + a\sin(\omega_d t) + a\,\delta_d(t)\sin(\omega_v t) + a\,\delta'(t)\sin(\omega_v' t),$$

则

$$D_v = \left|\delta' - \delta_d\right|\left|\partial_d J_v(u)\right| + O(a^2). \tag{13}$$

特别地，$\delta' \equiv \delta_d$ 给出 $D_v = O(a^2)$：**检测器读作诚实，而欺骗以任意强度进行中。** 而且这个规避对欺骗者第一阶不花钱——受害者的更新 (4) 只在 ω_v 解调， 多出来的分量平均掉了，DNE (6) 不变到 $O(a^2)$。

两个体重秤

你有两个秤，一个可能被动过手脚、一个是干净的，你比较两个读数来发现造假。**攻击者把两个秤动了同样的手脚**——差值又是零，你什么也发现不了。
设 $\delta' = \mu\delta_d$，则 (13) 变成 $D_v = |\mu - 1| \cdot |\delta_d\, \partial_d J_v|$——一个顶点在 $\mu = 1$ 的 V 形，斜率 ≈ 0.200。

镜像比 μ	0	0.25	0.5	0.75	**1**	1.25	1.5	2
D_v	0.2057	0.1559	0.1060	0.0561	**0.0061**	0.0440	0.0943	0.1952
DNE u_v	0.5424	0.5423	0.5421	0.5419	0.5417	0.5415	0.5412	0.5406
判定	欺骗				**诚实**			欺骗

在 $\mu = 1$ 处检测器读 0.0061，**低于诚实噪底** 0.00683，而攻击以全强度进行；DNE 只移动 6.6×10^{-4}，即规避免费到 $O(a^2)$。预测 V 形斜率 0.200，实测两支为 0.1996（左，0.4%）和 0.1891（右，6.5%）。

所以整个保证的准确表述是：探针保密（probe secrecy），而不是无条件可靠性（unconditional soundness）。
它不是“数学上不可能骗过”，而是“**只要你不知道我的监测频率，你就骗不过**”。保证的强度 = 受害者保守 ω_v' 的能力。
呈现顺序很重要：先说命题 2（坏消息），紧接着说命题 1（边界）。顺序反了变成“我做了个能被破解的东西”；顺序对了是“我知道我的定理适用在哪里”。

7 保密是时序条件，不是静态条件

注 5 (为什么保密必然会失效). 欺骗者的收益 J_d 通过 $\partial_v J_d \neq 0$ 依赖受害者的动作—— **而这正是欺骗有利可图的原因**。但受害者的动作 (1) 里带着它的探针，所以欺骗者读到的收益里也含有 ω_v' 频率的成分。

于是形成一个结构性的自相矛盾：欺骗者要么对 x_v 敏感（那它就能听见 ω_v'），要么对 x_v 不敏感（那它根本无法获利）。**它不能既获利、又对受害者的探针完全失聪**。

对自己的收益做频谱扫描，原则上能在获取时间 T_{acq} 后恢复 ω_v'；T_{acq} 由它的测量噪声和探测幅值 a 决定。因此假设 3 只在受害者以周期 T_{hop} 重抽 ω_v'、且

$$\underbrace{\frac{1}{\omega_{\min}}}_{\text{探针周期}} \ll \underbrace{T}_{\text{检测窗口}} \ll \underbrace{T_{\text{hop}}}_{\text{换频周期}} < \underbrace{T_{\text{acq}}}_{\text{破解时间}} \tag{14}$$

时才现实。中间那条说检测必须在两次重抽之间完成；右边那条说攻击者不能先估完。**右端的 T_{acq} 本文未处理**——它需要给欺骗者建一个观测/信息模型，是另一套工具。

注 6 (跳频在稳定性上是免费的). 注 5 把受害者变成一个切换系统，而定理 2 只分析单次切换。直觉上会冒出一个 dwell-time 下界——**而它会与 (14) 右端打架**：③要求换得快，稳定性可能要求换得慢，两者可能没有交集，整个方案就死了。

数值上没有这个冲突。受害者在五个可行频率间循环：

dwell (s)	20	5	1	0.2	**0.05**
恢复误差	1.5×10^{-3}	2.0×10^{-3}	3.1×10^{-3}	4.2×10^{-3}	$\mathbf{1.9\times10^{-2}}$

最短的 0.05 s 是 washout 时间常数 $\omega_h^{-1}=0.159$ s 的 1/3、慢时间常数 $k^{-1}=3.33$ s 的 1/67，单次运行**切换 3600 次**，全程无任何发散，误差始终在定理承诺的 $O(a)=0.05$ 带内。

原因是受害者的慢动态本来就在做平均：u_v 在 $1/k$ 尺度上演化，切换发生在远快于此的尺度上，它看不见单次切换。**精度平滑退化，稳定性完全不退化**。结论：T_{hop} 的约束来自检测窗口，不来自稳定性。

这是一个否定性结果，价值在于**消掉一个反对意见，而不是增加一条假设**。

注 7 (走向随机化检测器). 一个自然的加强是给受害者一组 m 个监测探针，随机抽取其中一个驱动 (4)。这会把镜像规避的要求从“猜中一个频率”提高到“同时镜像整组”，是对 命题 2 最直接的加固。定量化尚未完成。

8 主结果三：恢复

检测与恢复是同一个原语的两种用法。在触发时刻 t_0（$D_v>\rho$），受害者把驱动 (4) 的频率从 ω_v 重抽到秘密的 $\omega_v''\notin\{\omega_v,\omega_d\}$，且满足假设 2 与 3。

定理 2 (恢复)**.** 设假设 2, 3, 4, 6 成立。则存在 $\bar a>0$（依赖 $\bar\delta$）使得对每个 $a\in(0,\bar a)$ 存在 $\bar\omega(a)<\infty$ 与 $\bar\varepsilon(a)>0$：若探测频率超过 $\bar\omega(a)$ 且 $\varepsilon\in(0,\bar\varepsilon(a))$，则在 t_0 切换 $\omega_v\mapsto\omega_v''$ 之后，慢状态 $u(t)$ **指数收敛到** $u^\star$ **的** $O(a)$ **邻域**，对假设 4 下容许的每一条 $\delta_d(t)$ 轨迹都成立。

证明要点. 受害者现在在 ω_v'' 解调更新，而欺骗者（按假设 3）仍在 ω_v 注入。重复引理 1(a)，交叉项带 $\overline{\sin(\omega_v t)\sin(\omega_v'' t)}=0$（由 (7)）。感知梯度失去偏置，$\dot u=-kG_{\text{hon}}(u)+O(a^2)$，$\delta_d$ **不再出现在** u **动态中**，欺骗者的积分状态 (5) 与 u 解耦。

但解耦本身并不使 δ_d 无关：被忽略的 Taylor 余项带着因子 $a^2\delta_d^2\,\partial_{dd}^2J_v$ 和 $a^3\delta_d^3\,\partial^3J_v$，所以无界的 δ_d 会同时破坏摄动界与假设 1 所需的 $x_d\in U$ 的包含性。**假设 4 恰好提供所需的一致性**：在 $|\delta_d|\le\bar\delta$ 上余项被 $C(\bar\delta)a^2$ 控制，C 与 t 无关。其余是标准的 Lyapunov + 平均定理论证。 □

注 8 (切换目标必须可行，而这不是形式主义). 证明只需要 $\overline{\sin\omega_v t\,\sin\omega_v'' t}=0$，任何不同频率都给得出—— 容易让人以为“重抽”是自由的。**高阶项会咬人：**

$\omega_v''/2\pi$ (Hz)	最小 $\lvert m\rvert\le3$ 组合	共振?	到 $u^\star$ 的误差
16.4	1.80	否	0.0014
$15.0=3\omega_v$	0.40	仅在 $\lvert m\rvert=4$	0.0016
13.9	0.70	否	0.0021
$10.0=2\omega_v$	0，于 $m=(2,-1,0)$	**是**	0.0059
$12.3=\omega_v+\omega_d$	0，于 $m=(1,-1,1)$	**是**	**0.0267**

假设 2 中的 $|m|\le3$ **两个方向都是紧的**：放松它会放进代价 4 倍和 19 倍的目标；收紧到 $|m|\le4$ 会排除掉毫无代价的 $3\omega_v$。

8.1 恢复之后：积分饱和与三个出口

推论 2 (恢复后的积分饱和). 设欺骗者运行不带饱和的 (5)，且定理 2 的结论在 $[t_0, t_1]$ 上成立，故 $J_d(u(t)) \to J_d(u^\star)$。设这次欺骗值得做，即 $\gamma := J_d(u^\star) - J_d^{\mathrm{ref}} \neq 0$。则对每个 $\theta \in (0,1)$ 存在 t_1 使

$$\big|\delta_d(t)\big| \;\geq\; \big|\delta_d(t_1)\big| + \theta\,\varepsilon|\gamma|\,(t - t_1), \qquad t \geq t_1, \tag{15}$$

即 δ_d 在有限时间内离开任何有界集，欺骗者的动作扰动 $a|\delta_d|$ 无界增长。

数值：预测 $\varepsilon\gamma = 4.331 \times 10^{-3}$，实测拟合 4.68×10^{-3}，误差 8.1%。在执行器限幅 $a|\delta_d| \leq 0.5, 1, 2$ 下，切换后到“肉眼可见”的时间约为 2.4×10^3、4.5×10^3、8.8×10^3 个时间单位。

注 9 (恢复以三种方式终结欺骗). 推论 2 补上了定理 2 留下的缺口：

欺骗者行为	最终 u_v	到 $u^\star$ 的误差	最终 δ_d
不饱和	0.7714	2.15×10^{-3}	3.5291（发散中）
在 $\bar{\delta} = 0.5$ 饱和	0.7712	2.01×10^{-3}	0.5000
放弃攻击（$\varepsilon = 0$）	0.7712	2.00×10^{-3}	0

不饱和者的注入振幅在已知频率上线性发散，任何频谱监测都看得见，更不用说它违反的执行器限制；**饱和**者满足假设 4，定理 2 逐字成立，注入在没人解调的频率上徒劳持续；**放弃**者令 $\delta_d \to 0$，博弈变回诚实。

三种情况受害者最终误差差别不到 2×10^{-4}：**欺骗在每种情况下都终结了，唯一的区别是欺骗者自己的状态是否有界。**欺骗者所利用的那个不对称——单一影响通道、位于受害者被迫持续使用的频率上——在受害者获得自由移动的那一刻就消失了。

> **关于“投影到紧集”的说明。**一个自然的修法是照 arXiv:2407.05168 把 δ 投影到紧集上。本文没有这么做，因为那样会丢掉推论 2：把无界性当成需要修的技术漏洞，就看不到“恢复终结欺骗”这个结论。需要强调的是，**投影正是假设 4 的一种构造性实现**——区别只在于把它放进算法（投影）还是放进假设（有界注入）并证明不满足它会怎样。两种呈现都成立，可以并列给出。

9 设计变量是 k/ω，不是 a

注 10 (残差在 a 上非单调). 读 (10) 的自然反应是“把 a 取小”。**这是反的。**残差分解为两部分：曲率偏差 $O(a^2)$，以及由相对纹波 $\nu = k/(a\omega_{\min})$ 贡献的 $O(\nu^2)$——后者随 a 减小而增大：

$$\eta \lesssim C_1 a^2 + C_2\Big(\frac{k}{a\,\omega_{\min}}\Big)^2, \qquad a^\star = \Big(\frac{C_2}{C_1}\Big)^{1/4}\sqrt{\frac{k}{\omega_{\min}}}, \qquad \eta_{\min} = 2\sqrt{C_1 C_2}\,\frac{k}{\omega_{\min}}. \tag{16}$$

于是设计条件 (11) **实际上是对 $k/\omega_{\min}$ 的条件，不是对 a 的**：

$$\frac{k}{\omega_{\min}} \lesssim \frac{\delta_{\min} c_0}{8\sqrt{C_1 C_2}}.$$

这也是第 2.1 节那个“取 a 小最终会违反平均假设”的定量形式。

a	$\nu = k/(a\omega_{\min})$	η	η/ν^2
0.025	0.3820	**0.02739**	0.188
0.050	0.1910	0.00683	0.187
0.100	0.0955	0.00171	0.187
0.150	0.0637	0.00076	0.187

扫 a、k 与整体频率尺度，拟合得 $\eta \approx 0.191\,(k/a\omega_{\min})^2$，散布 1.9%； $C_1 a^2$ 在整个扫描范围内都低于分辨率，说明残差完全由纹波项支配。**把 a 从 0.05 减半到 0.025，η 从 0.00683 涨到 0.02739——几乎撞上阈值** $\rho = 0.03$。 在所考察的范围内，a 应当增大而非减小，直到曲率项开始可见为止。

注 11 (有限平均窗口). 实现要把 $\bar{\cdot}$ 换成滑动窗 $\frac{1}{T}\int_{t-T}^{t}$。这带来两个方向相反的要求： 窗口纹波 $O(1/(\omega_{\min}T))$ 要求 T 大；而恒等式要在暂态中成立需要 u 在窗口内近似冻结， 即 $T \ll 1/k$。**但两者并不对称：**

- **下界是硬的**。若窗口纹波超过 (16) 的固有噪底，它就支配 η 并直接产生误报。
- **上界是软的**。超过 $T \ll 1/k$ 并不破坏稳态检验，只是逐渐劣化暂态恒等式误差。

本文的博弈中 $k/\omega_{\min} = 9.5 \times 10^{-3}$，名义区间 $(\omega_{\min}^{-1}, k^{-1}) = (0.03, 3.3)$ s 有两个数量级宽，**然而其中每一个窗口都产生误报**；最小可用值是 $T = 10$ s $= 3k^{-1}$。 暂态误差在 $T = 10$ 时最小，到 $T = 40$ 也只翻了一倍。 实用规则：取纹波刚好低于噪底的最小 T，并把 $T \ll 1/k$ 读作对暂态保真度的提醒， 而非硬约束。

10 数值验证

所有运行都用 RK4 积分**真实的时变系统** (1)–(5)， 从不积分平均系统——平均系统按构造就满足那些恒等式，证明不了任何东西。

基准博弈（强单调二次型）：

$$J_v = \tfrac{1}{2}(x_v - 1)^2 + c\,x_v x_d + e\,x_d, \qquad J_d = \tfrac{1}{2}(x_d - 1)^2 + c\,x_v x_d, \qquad c = 0.3,\ e = 0.5,$$

参数 $a = 0.05$， $k = 0.30$， $\varepsilon = 0.08$， 探测频率 $2\pi\{5,\ 7.3,\ 11.7\}$ 对应 $\{\omega_v, \omega_d, \omega_v'\}$， washout $\omega_h = 2\pi$， $J_d^{\mathrm{ref}} = 0.15$，步长 $\Delta t = 5 \times 10^{-4}$， 滑动窗 $T = 10$，阈值 $\rho = 0.03$。 第 9 节的三次变体为 $J_v + \frac{q}{3}x_v^3$， $q = 0.4$。

10.1 解析基准（先解，不拟合）

量	值
真 NE $u^\star$	$(0.769231,\ 0.769231)$
诚实时欺骗者收益 $J_d(u^\star)$	0.204142
DNE u^*	$(0.544467,\ 0.836660)$
注入 δ^*	0.308342
受害者真梯度 $\partial_v J_v(u^*)$	-0.204535 （不为零）
耦合 $\partial_d J_v(u^*)$	0.663340
预测 $D_v = \lvert\delta^*\rvert\lvert\partial_d J_v(u^*)\rvert$	0.204535
积分饱和速率 $\varepsilon\gamma$，$\gamma = 0.054142$	4.331×10^{-3}

(6) 的三个条件在该点分别满足到 1.7×10^{-14}、2.8×10^{-17}、1.6×10^{-15}。 注意第五行与第七行数值相同：**那是恒等式，不是两个独立测量**。

欺骗确实做到了它该做的：受害者代价从 0.5922 升到 0.6603， 欺骗者代价从 0.2023 降到 0.1495（目标 0.150）。

10.2 汇总表

§	被检验的论断	结果	判定
1	解析 DNE 自洽	$\delta^* = 0.30834$， $D_v^{\text{pred}} = 0.20454$	基准
2	DNE 位置与理论一致	$\lvert\Delta u_v\rvert = 2.09 \times 10^{-3}$	通过（$O(a^2)$）
3	引理 2：$\lvert C_v\rvert$ 诚实 vs 欺骗	1.48×10^{-13} vs 6.13×10^{-5}	如所述之盲
3	动作残差	1.58×10^{-2} vs 1.45×10^{-2}	如所述之盲
4	引理 1(a)/(b) 残差	0.01139 / 0.00981	通过
5	定理 1：D_v 实测 vs 解析	0.20571 vs 0.20454（0.57%）	通过
5	推论 1 分离	$0.00683 < 0.03 < 0.20519$	成立（30×）
5	第二探针的代价	DNE 移动 5.38×10^{-6}	可忽略
6	命题 2 镜像规避	D_v： $0.20571 \to 0.00609$	**检测器被击破**
7	推论 2 饱和速率	0.00468 vs $\varepsilon\gamma = 0.00433$	通过（8.1%）
7	切频后恢复	$u_v = 0.7714$ vs $u^\star = 0.7692$	通过
9	重复跳频	dwell 0.05 s，3600 次切换稳定	未发现 dwell 下界
10	残差标度	$\eta \approx 0.19\,(k/a\omega)^2$	**修正推论 1**
11	窗口长度	名义区间内全部误报，最小可用 $T = 10$ s	见注 11
12	测量噪声	$\sigma = 0.05$ 时误报率 25.7%	**待办**
13	收益–可检测性	$r = 0.9998$	单调
14	切换目标	最差 12.3 Hz，误差 0.0267（19×）	可行集要紧
15	非二次博弈	$D_v = 0.18712$ vs 预测 0.18922（1.11%）	通过

10.3 值得单独说明的几项

恒等式沿轨迹成立，不只在极限。 (10) 对 $\lvert\delta_d(t)\rvert\lvert\partial_d J_v(u(t))\rvert$ 的逐点误差 在暂态 $t \in (40, 240)$ 上平均 0.0035，稳态 0.0056。 诚实噪底 $\eta = 0.00683$（均值与最大值前五位相同）对欺骗最小值 0.20519， 阈值 $\rho = 0.03$ 以 30 倍余量分离两个区制，既无误报也无漏报。

共模抵消是可测的。 η 小于第 4 行中任一单独解调的偏差（0.0114、0.0098），这正是注 3 所说的共模抵消。

非二次博弈真正加载了三阶余项。 二次博弈中 $\partial^3 J \equiv 0$，引理 1 证明里的三阶余项恒为零、从未受检。加入 $\frac{q}{3}x_v^3$ 后：真 NE 0.6072，解析 DNE $u_v = 0.4659$、$\delta = 0.2958$，D_v 实测 0.18712 对预测 0.18922（1.11%），诚实噪底 0.00628，分离依然成立。同时 $3\omega_v$ 作为跳频目标（仅在 $|m| = 4$ 共振）在三次博弈中仍与最佳目标无异，证实了注 8 中 $|m| \le 3$ 的紧性。

11 开放问题与下一步

1. T_{acq}**：欺骗者的信息模型。** (14) 最右端尚未处理。它需要给欺骗者建一个观测模型——测量噪声、扫描策略、估计器—— 从而给出“多久能估出 ω_v'”的定量答案。这是本项目最有可能导出独立后续工作的方向。

2. **随机化监测探针组。** 注 8 的加固方案：m 个候选探针中随机抽一个驱动更新。需要定量化它把命题 2 的规避成功率压到多少（直觉上是 $1/m$ 量级，但镜像整组的代价需要单独算）。

3. **噪声下的阈值标定。** $\sigma = 0.05$ 时固定阈值给出 25.7% 的误报率。需要噪声相关的阈值标定，或换成自适应统计检测（CUSUM / GLRT）。这是审稿人最可能攻击的点。

4. **投影版本的恢复。** 是否与推论 2 并列给出一个把 δ 投影到紧集的构造性版本，作为假设 4 的实现。

5. **向量与 N 人推广。** 把 $\partial_v J_v, \partial_d J_v$ 换成 Jacobian 块 $\nabla_v J_v, \nabla_d J_v$，标量 δ_d 换成注入幅度向量 δ，绝对值换成欧氏范数。引理 1 逐分量成立，(10) 变为 $D_v = \|(\nabla_d J_v)\delta\| + O(a^2)$；**值得注意的是**，命题 2 变为 $D_v = \|(\nabla_d J_v)(\delta' - \delta)\| + O(a^2)$，于是当 $n_v < n_d$ 时存在 $\delta' \neq \delta$ 的规避解—— 欺骗者只需在 $\ker(\nabla_d J_v)$ 的意义下匹配注入即可。目前只是概述，未给出完整证明。

A 附录：汇报要点

呈现顺序。 先讲三条主结果的逻辑链（10 分钟，只讲骨架不展开推导），再讲三条边界，最后讲开放问题。**命题 2 必须主动提出**，不要等人问；提出后紧接着给命题 1 作为边界。

最容易被追问的四个点，以及一句话回答：

1. “为什么用差而不是 C_v' 单独？”
   → 单测 $|C_v'|$ 会对每一次未收敛的诚实运行报警；相减买到的是“在每个 t 都有效”。见注 3。

2. “washout 是不是可以省？”
   → 不能。省掉后收益的直流分量被 $1/a$ 放大成幅度 $k/(a\omega)$ 的纹波，本文参数下是探针的 4.5 倍，回路失稳；频率要求变成不可行的 a^{-2}。

3. “反复换频会不会破坏稳定性？”
   → 测了。dwell 压到 washout 时间常数的 1/3、单次运行 3600 次切换，无发散。T_{hop} 的约束来自检测窗口，不来自稳定性。见注 6。

4. “这和 arXiv:2407.05168 的关系？”
   → 那篇建立了欺骗能稳定地把系统推到 DNE；本文处理受害者一侧：同一个解调原语既是检测手段也是恢复手段，并且证明了可检测性与收益是锁死的。

一个措辞上的提醒。 不要说“结果全都成立了”。 本文最强的地方恰恰是它把三条结论的边界都划了出来—— 可被精确规避、积分状态发散、残差在 a 上非单调。 **“知道自己的方法什么时候会坏”**比“全都 work”可信得多。